



UMCS

UNIwersytet Marii Curie-Skłodowskiej
w Lublinie

Wydział Matematyki, Fizyki i Informatyki

Kierunek: **Geoinformatyka**

Specjalność:

Krystian Banach

Nr albumu: 307619

Projekt i implementacja oprogramowania do analizy i przetwarzania tras GPX na potrzeby zawodów sportowych

Design and implementation of software for analyzing and
processing GPX routes for sports competitions

Praca magisterska
napisana w Katedrze Oprogramowania Systemów Informatycznych
Instytutu Informatyki
pod kierunkiem dr Michała Klisowskiego

Lublin 2026

Spis treści

Streszczenie	5
Wstęp	7
1 Teoretyczne podstawy analizy tras GPX	9
1.1 Pamięć i wydajność obliczeń	9
1.1.1 Pamięć podręczna i hierarchia pamięci	10
1.1.2 Równoległe wykonywanie operacji	11
1.1.3 Wektoryzacja	11
1.2 Dane GPS i format GPX	12
1.2.1 Charakterystyka danych GPS	13
1.2.2 Struktura pliku GPX	13
1.2.3 Układy współrzędnych w analizie tras	14
1.3 Metody analizy i porównywania tras	15
1.3.1 Obliczanie dystansu i przewyższeń	16
1.3.2 Porównywanie trasy z trasą referencyjną	17
1.3.3 Dyskretna odległość Frécheta	18
2 Reprezentacja danych i narzędzia obliczeniowe w Pythonie	21
2.1 Python i reprezentacja danych liczbowych	21
2.1.1 Listy Pythona i dynamiczne typowanie	21
2.1.2 NumPy i tablice numeryczne	21
2.1.3 Numba i kompilacja JIT	21
3 Projekt i implementacja oprogramowania do analizy tras GPX	23
3.1 Struktura projektu	23
3.2 Implementacja parsera plików GPX	23
3.3 Implementacja operacji analizy tras	23
3.3.1 Obliczanie dystansu i przewyższeń	23
3.3.2 Porównywanie trasy zawodnika z trasą referencyjną	23
3.3.3 Obliczanie dyskretnej odległości Frécheta	23

3.4 Implementacja benchmarków	23
Bibliografia	25
Spis listingów	27

Streszczenie

kiedys tu coś napisze może

Wstęp

kiedys tu coś napisze

Rozdział 1

Teoretyczne podstawy analizy tras GPX

Rozdział przedstawia podstawy teoretyczne potrzebne do omówienia projektu oraz implementacji oprogramowania analizującego trasy zapisane w formacie GPX. Punktem wyjścia jest charakterystyka danych wejściowych, czyli śladów GPS złożonych z kolejnych punktów opisujących położenie użytkownika. W formacie GPX współrzędne geograficzne punktu śladu są zapisywane w atrybutach `lat` i `lon`, natomiast wysokość oraz czas pomiaru mogą być reprezentowane odpowiednio przez elementy `ele` i `time`. [3]. Na tej podstawie omówiono operacje analityczne wykonywane na trasach, takie jak obliczanie dystansu, wyznaczanie przewyższeń, porównywanie śladu zawodnika z trasą referencyjną oraz obliczanie dyskretnej odległości Fréchet’a.

Istotną częścią rozdziału jest również omówienie zagadnień związanych z wydajnością obliczeń. Przetwarzanie tras GPX wymaga wielokrotnego wykonywania operacji na sekwencjach wartości liczbowych, dlatego znaczenie mają nie tylko zastosowane algorytmy, lecz także sposób reprezentacji danych w pamięci oraz możliwość wykorzystania operacji tablicowych. Przedstawione zagadnienia stanowią podstawę do dalszego opisu wariantów implementacyjnych opartych na listach Pythona, tablicach NumPy oraz kompilacji JIT z użyciem biblioteki Numba.

1.1 Pamięć i wydajność obliczeń

Wydajność programów przetwarzających duże zbiory danych zależy nie tylko od liczby wykonywanych operacji arytmetycznych, lecz również od sposobu organizacji dostępu do pamięci. Współczesne procesory mogą wykonywać operacje szybciej, niż dane są dostarczane z pamięci operacyjnej, dlatego w architekturze komputera stosuje się hierarchię pamięci obejmującą między innymi rejestry, pamięć podręczną oraz pamięć główną. [1, 2] Efektywność wykorzystania tej hierarchii zależy między innymi od lokalności czasowej

i przestrzennej odwołań do danych.[2]

Trasy zapisane w formacie GPX mogą być przetwarzane jako uporządkowane sekwencje punktów śladu `trkpt`. [3] Operacje takie jak obliczanie dystansu, sumowanie przewyższeń lub porównywanie śladu z trasą referencyjną wymagają wielokrotnego przechodzenia po kolejnych wartościach liczbowych. Z tego powodu sposób reprezentacji danych może wpływać zarówno na koszt dostępu do pamięci, jak i na możliwość zapisu obliczeń w postaci operacji tablicowych.

1.1.1 Pamięć podręczna i hierarchia pamięci

Pamięć podręczna procesora pełni funkcję szybkiej warstwy pośredniczącej pomiędzy jednostką centralną a pamięcią operacyjną. Jej zastosowanie wynika z różnicy prędkości pomiędzy procesorem a pamięcią główną: dane używane niedawno lub potencjalnie potrzebne w najbliższym czasie mogą zostać umieszczone bliżej procesora.[1] Dzięki temu część odwołań do danych może zostać obsłużona bez każdorazowego pobierania ich z pamięci głównej.

Działanie pamięci podręcznej jest związane z pojęciami trafienia oraz chybienia. Trafienie cache występuje wtedy, gdy poszukiwane dane znajdują się już w pamięci podręcznej i mogą zostać z niej odczytane. Chybiecie oznacza natomiast konieczność pobrania danych z niższego poziomu hierarchii pamięci i umieszczenia ich w cache.[2]

Podstawą efektywnego wykorzystania pamięci podręcznej jest lokalność odwołań. Lokalność czasowa oznacza możliwość ponownego użycia danych wykorzystywanych niedawno, natomiast lokalność przestrzenna dotyczy korzystania z danych położonych blisko siebie w przestrzeni adresowej.[2] Szerszy kontekst analizy zachowania programu w pamięci stanowi model zbioru roboczego Denninga, w którym zbiór roboczy oznacza zbiór informacji używanych przez proces w określonym ostatnim przedziale czasu.[4]

Istotną cechą pamięci podręcznej jest blokowy sposób przenoszenia danych między pamięcią główną a cache. Pamięć główna jest traktowana jako zbiór bloków adresowanych komórek, natomiast pamięć podręczna składa się z wierszy odpowiadających takim blokom.[2] Odczyt jednej wartości może więc spowodować przeniesienie do pamięci podręcznej również wartości sąsiednich, co sprzyja programom przetwarzającym dane ułożone kolejno w pamięci.

Z tej perspektywy wybór struktury danych ma znaczenie nie tylko organizacyjne, lecz także wydajnościowe. Dane przechowywane w sposób ciągły, na przykład w tablicach, sprzyjają sekwencyjnemu odczytowi i mogą lepiej odpowiadać sposobowi działania pamięci podręcznej.[2] Mniej korzystny z punktu widzenia lokalności pamięci może być model, w którym dane są reprezentowane jako wiele odrębnych obiektów powiązanych odwołaniami, ponieważ kolejne logiczne elementy przetwarzanej sekwencji nie muszą znajdować się obok siebie w pamięci. W języku Python dane programu są reprezentowane jako obiek-

ty posiadające tożsamość, typ i wartość.[6] Taki model jest istotny przy porównaniu list Pythona z jednorodnymi tablicami numerycznymi.

W analizie wydajności można również odwołać się do rozróżnienia między kodem ograniczonym wydajnością jednostek obliczeniowych a kodem ograniczonym przepustowością pamięci. Model Roofline opisuje tę zależność przez intensywność obliczeń, czyli relację między liczbą wykonywanych operacji a ilością danych przesyłanych z pamięci.[7]

1.1.2 Równoległe wykonywanie operacji

Wydajność obliczeń numerycznych może być zwiększana nie tylko przez zmianę algorytmu, lecz także przez wykorzystanie równoległości dostępnej na poziomie sprzętu i sposobu wykonania programu. Jednym z klasycznych sposobów opisu architektur obliczeniowych jest taksonomia Flynna, dzieląca systemy według liczby strumieni instrukcji i danych. W kontekście obliczeń numerycznych szczególne znaczenie ma model SIMD, czyli *Single Instruction, Multiple Data*, w którym jedna instrukcja jest wykonywana dla wielu elementów danych.[8]

Model SIMD jest istotny wtedy, gdy ta sama operacja może zostać zastosowana do wielu wartości liczbowych. W analizie tras GPX taki charakter mają między innymi operacje na współrzędnych, wysokościach oraz różnicach między sąsiednimi punktami. Jednorodna reprezentacja danych i uporządkowany układ wartości w pamięci mogą sprzyjać przetwarzaniu wielu elementów według tego samego schematu obliczeń.

W taksonomii Flynna wyróżnia się również model MIMD, czyli *Multiple Instruction, Multiple Data*, w którym równoległość dotyczy zarówno strumieni instrukcji, jak i strumieni danych.[8] Taki model można odnieść na przykład do niezależnego przetwarzania wielu tras lub wielu plików GPX. Możliwe przyspieszenie programu równoległego jest jednak ograniczone przez część obliczeń, której nie można wykonać równoległe, co opisuje prawo Amdahla.[9]

1.1.3 Wektoryzacja

Wektoryzację można rozumieć jako sposób zapisu lub wykonania obliczeń, w którym ta sama operacja jest stosowana do wielu elementów danych zamiast do pojedynczych wartości przetwarzanych osobno. Jej idea jest powiązana z modelem SIMD, ponieważ w obu przypadkach istotne jest wykonanie tego samego schematu obliczeń dla wielu wartości liczbowych.[8] W standardzie OpenMP konstrukcja `simd` służy do wskazania, że iteracje pętli mogą zostać wykonane z użyciem instrukcji wektorowych, jeżeli spełnione są warunki poprawnościowe.[10]

W analizie danych GPX wektoryzacja może być użyteczna dla operacji wykonywanych na sekwencjach wartości liczbowych, takich jak obliczanie różnic wysokości, przeliczanie

współrzędnych, wykonywanie funkcji trygonometrycznych dla wielu punktów lub sumowanie odległości między kolejnymi próbkami trasy. Tego typu obliczenia można często zapisać jako działania na tablicach numerycznych, ograniczając udział jawnych pętli wykonywanych bezpośrednio w kodzie Pythona.

Istotnym czynnikiem wpływającym na możliwość efektywnego wykorzystania wektoryzacji jest reprezentacja danych. Dane jednorodne, liczbowe i ułożone w sposób sprzyjający lokalności przestrzennej łatwiej zapisać jako operacje tablicowe niż dane rozproszone jako wiele odrębnych obiektów.[2] W języku Python dane programu są reprezentowane jako obiekty posiadające tożsamość, typ i wartość,[6] dlatego porównanie list Pythona z jednorodnymi tablicami numerycznymi wymaga uwzględnienia nie tylko samego algorytmu, lecz także sposobu reprezentacji danych.

Dyrektywy OpenMP nie są wykorzystywane w implementacji; konstrukcja `simd` służy jedynie jako przykład jawnego wskazania pętli możliwej do wykonania z użyciem instrukcji wektorowych.[10] Nie każda operacja tablicowa prowadzi jednak automatycznie do skrócenia czasu wykonania. Efektywność takiego podejścia zależy od charakteru algorytmu, układu danych w pamięci oraz sposobu wykonania operacji przez użyte narzędzia obliczeniowe.

1.2 Dane GPS i format GPX

Dane wykorzystywane w analizie tras sportowych można traktować jako uporządkowany zapis kolejnych położень użytkownika. W formacie GPX ślad trasy jest reprezentowany przez element `trk`, który może zawierać segmenty `trkseg`. Segmenty te składają się z kolejnych punktów śladu `trkpt`, opisujących przebieg trasy.[3] Pojedynczy punkt śladu zawiera współrzędne geograficzne zapisane w atrybutach `lat` i `lon`, a dodatkowo może zawierać wysokość `ele` oraz czas pomiaru `time`.[3]

Taka struktura danych jest istotna obliczeniowo, ponieważ trasa nie jest pojedynczą geometrią, lecz sekwencją próbek. Kolejność punktów pozwala obliczać odległości między sąsiednimi pozycjami, wyznaczać zmiany wysokości oraz porównywać przebieg śladu z trasą referencyjną. W dalszych częściach rozdziału omówiono najpierw charakter danych GPS, następnie strukturę pliku GPX oraz znaczenie układów współrzędnych w analizie tras.

Dane pozycyjne rejestrowane przez odbiorniki GPS/GNSS należy traktować jako dane obarczone niepewnością pomiarową. Na dokładność pomiaru mogą wpływać między innymi warunki terenowe, jakość odbiornika oraz zjawisko wielotorowości sygnału, polegające na docieraniu sygnału do odbiornika wieloma drogami wskutek odbić od przeszkód terenowych lub obiektów znajdujących się w otoczeniu.[11] Ograniczona dokładność danych wejściowych ma znaczenie dla obliczeń pochodnych, takich jak długość trasy, suma

podejść, suma zejść czy lokalne odchylenie śladu od trasy referencyjnej.

1.2.1 Charakterystyka danych GPS

Dane GPS rejestrowane podczas aktywności sportowej mają charakter sekwencyjny. Kolejne punkty zapisu odpowiadają następującym po sobie pomiarom położenia użytkownika, dlatego ślad trasy można analizować jako uporządkowany ciąg próbek. Taka reprezentacja jest podstawą operacji polegających na porównywaniu sąsiednich punktów, między innymi przy obliczaniu dystansu oraz zmian wysokości.

Sekwencyjny charakter danych jest istotny, ponieważ wiele operacji analizy trasy opiera się na relacjach między sąsiednimi punktami śladu. Kolejność punktów ma również znaczenie przy porównywaniu śladu zawodnika z trasą referencyjną, ponieważ przebieg trasy jest analizowany jako uporządkowany ciąg położeń, a nie jako nieuporządkowany zbiór punktów.

Pomiar GPS/GNSS może zawierać zakłócenia. Według Januszewskiego jednym z typowych źródeł błędów jest wielotorowość sygnału, czyli sytuacja, w której sygnał satelitarny dociera do odbiornika różnymi drogami wskutek odbić od przeszkód terenowych lub obiektów znajdujących się w otoczeniu.[11] Z tego powodu wyniki obliczeń wykonywanych na podstawie śladów GPS należy interpretować z uwzględnieniem ograniczonej dokładności danych wejściowych.

1.2.2 Struktura pliku GPX

GPX jest formatem zapisu danych geograficznych opartym na XML. Dokumentacja GPX 1.1 opisuje plik jako hierarchię elementów XML, w której elementem głównym jest `gpx`. [3] W analizie śladów sportowych szczególne znaczenie ma część struktury związana z zapisem trasy jako śladu, obejmująca elementy `trk`, `trkseg` oraz `trkpt`.

Wykorzystywana w dalszym przetwarzaniu hierarchia elementów ma następującą postać:

- `gpx` – element główny dokumentu,
- `metadata` – metadane pliku,
- `trk` – ślad zarejestrowanej aktywności,
- `trkseg` – segment śladu,
- `trkpt` – pojedynczy punkt śladu.

Punkt śladu `trkpt` zawiera atrybuty `lat` i `lon`, określające odpowiednio szerokość i długość geograficzną punktu. Dodatkowo punkt może zawierać element `ele`, przechowyujący wysokość, oraz element `time`, określający czas rejestracji próbki.[3] Sposób obsługi

plików, w których część tych wartości nie występuje, zależy od przyjętej logiki parsera i zostanie omówiony w rozdziale implementacyjnym.

Listing 1.1 przedstawia uproszczony fragment pliku GPX obejmujący elementy istotne dla dalszego przetwarzania: `metadata`, `trk`, `trkseg`, `trkpt`, atrybuty `lat` i `lon` oraz elementy `ele` i `time`.

Listing 1.1: Fragment przykładowego pliku GPX

```
1 <gpx creator="Garmin Connect" version="1.1"
2   xmlns="http://www.topografix.com/GPX/1/1">
3   <metadata>
4     <time>2026-03-12T18:26:20.000Z</time>
5   </metadata>
6   <trk>
7     <type>20260312Bieg na dworze</type>
8     <trkseg>
9       <trkpt lat="51.231531" lon="22.506655">
10        <ele>125.8</ele>
11        <time>2026-03-12T18:26:20.000Z</time>
12      </trkpt>
13    </trkseg>
14  </trk>
15</gpx>
```

Przedstawiony fragment pokazuje sposób zapisu pojedynczego punktu śladu. Atrybuty `lat` i `lon` określają położenie punktu, element `ele` przechowuje wysokość, natomiast `time` zawiera czas rejestracji próbki. Na podstawie kolejnych elementów `trkpt` można utworzyć sekwencję punktów trasy stanowiącą dane wejściowe dla operacji analitycznych.

W plikach GPX mogą występować również rozszerzenia oraz dodatkowe informacje wykraczające poza podstawowe elementy punktów śladu.[3] W obliczeniach wykonywanych w przygotowanym programie wartości takie jak dystans czy suma przewyższeń nie są jednak odczytywane jako gotowe metryki z pliku, lecz wyznaczane ponownie na podstawie kolejnych punktów trasy. Pozwala to porównywać warianty implementacyjne wykonujące te same operacje na tych samych danych wejściowych.

Format GPX, jako format tekstowy oparty na XML, wymaga wydobycia danych ze struktury dokumentu przed rozpoczęciem właściwych obliczeń.[3] Dlatego w implementacji konieczne jest oddzielenie etapu parsowania pliku od etapu obliczeń wykonywanych na przygotowanej reprezentacji danych.

1.2.3 Układy współrzędnych w analizie tras

Zapis pozycji w danych GPS oraz w formacie GPX opiera się na globalnym układzie odniesienia WGS84. W tym układzie pozycja jest opisywana za pomocą współrzędnych

geograficznych: szerokości i długości geograficznej.[12] Dokumentacja GPX 1.1 wskazuje, że współrzędne w pliku GPX odnoszą się do układu WGS84, natomiast wartości takie jak wysokość są wyrażane w jednostkach metrycznych.[3]

Konsekwencją takiego sposobu zapisu jest konieczność rozróżnienia obliczeń wykonywanych na współrzędnych geograficznych i obliczeń wymagających układu metrycznego. Szerokość i długość geograficzna są wyrażane w stopniach, dlatego nie powinny być traktowane bezpośrednio jako współrzędne kartezjańskie w metrach. Przy obliczaniu odległości między punktami na powierzchni Ziemi należy zastosować wzór uwzględniający geograficzny charakter współrzędnych, natomiast operacje geometryczne wykonywane w płaszczyźnie wymagają transformacji danych do odpowiedniego układu metrycznego.

W analizie tras GPX rozróżnienie to ma znaczenie praktyczne. Dystans między sąsiednimi punktami może być obliczany na podstawie szerokości i długości geograficznej z użyciem wzoru Haversine’a, natomiast porównywanie punktu śladu z segmentem trasy referencyjnej wymaga reprezentacji, w której odległość ma interpretację metryczną. Dlatego dla operacji geometrycznych przewidziano transformację współrzędnych do układu płaskiego, docelowo EPSG:2180.

1.3 Metody analizy i porównywania tras

Metody wykorzystywane do analizy tras GPX można podzielić według rodzaju danych, na których operują, oraz według kosztu obliczeniowego. Najprostsze operacje dotyczą pojedynczego śladu i polegają na przejściu po kolejnych punktach trasy. Do tej grupy należą obliczanie dystansu oraz wyznaczanie sumy podejść i zejść. Ich wynik zależy od relacji między sąsiednimi próbkami, dlatego naturalnym modelem obliczeń jest sekwencyjne przetwarzanie uporządkowanego ciągu punktów.

Bardziej złożone są metody porównujące ślad zawodnika z trasą referencyjną. Wymagają one analizy relacji między dwoma przebiegami trasy, na przykład przez wyznaczanie odległości punktów śladu od segmentów linii referencyjnej albo przez porównanie dwóch sekwencji punktów jako całości. W tym drugim przypadku wykorzystana może być dyskretna odległość Frécheta, która uwzględnia nie tylko położenie punktów, lecz także ich kolejność w obu porównywanych sekwencjach.[19]

Podział metod ma znaczenie dla późniejszej oceny wydajności. Operacje wykonywane na pojedynczej trasie mogą być realizowane przez jednokrotne przejście po punktach, natomiast porównywanie tras wymaga rozpatrywania relacji między punktami lub segmentami dwóch śladów. Różnice te wpływają na liczbę wykonywanych operacji oraz na możliwość wykorzystania reprezentacji tablicowej lub kompilacji JIT.

1.3.1 Obliczanie dystansu i przewyższeń

Jedną z podstawowych operacji wykonywanych na śladzie GPX jest obliczenie długości trasy. Ponieważ ślad ma postać uporządkowanej sekwencji punktów, dystans można wyznaczyć jako sumę odległości między kolejnymi punktami. W badaniach dotyczących tras trailowych i górskich odległość między sąsiednimi punktami pliku GPX obliczano na podstawie współrzędnych geograficznych, traktując ją jako odległość poziomą, natomiast pionowe przemieszczenie między punktami analizowano oddzielnie jako składnik sumy podejść lub zejść.[13]

Odległość między kolejnymi punktami może być obliczana z użyciem wzoru Haversine'a, który pozwala wyznaczyć odległość po wielkim kole między dwoma punktami opisanymi szerokością i długością geograficzną.[14] Dla punktów o szerokościach geograficznych ϕ_1 , ϕ_2 oraz długościach geograficznych λ_1 , λ_2 , przyjmuje się:

$$\Delta\phi = \phi_2 - \phi_1,$$

$$\Delta\lambda = \lambda_2 - \lambda_1.$$

Następnie obliczana jest wartość pomocnicza:

$$a = \sin^2\left(\frac{\Delta\phi}{2}\right) + \cos\phi_1 \cos\phi_2 \sin^2\left(\frac{\Delta\lambda}{2}\right).$$

Odległość między punktami jest wyznaczana jako:

$$d = 2R \operatorname{atan2}\left(\sqrt{a}, \sqrt{1-a}\right),$$

gdzie R oznacza przyjęty promień Ziemi, a d oznacza odległość między punktami po powierzchni sfery. Przed podstawieniem do wzoru wartości szerokości i długości geograficznej muszą zostać wyrażone w radianach.[14]

Długość całej trasy obliczana jest jako suma odległości dla wszystkich par sąsiednich punktów śladu:

$$D = \sum_{i=1}^{n-1} d(p_i, p_{i+1}),$$

gdzie n oznacza liczbę punktów trasy, a $d(p_i, p_{i+1})$ oznacza odległość między punktem p_i oraz punktem p_{i+1} .

Suma podejść i suma zejść są wyznaczane na podstawie różnic wysokości między kolejnymi punktami. Dla dwóch sąsiednich punktów różnicę wysokości można zapisać jako:

$$\Delta h_i = h_{i+1} - h_i.$$

Suma podejść obejmuje dodatnie różnice wysokości:

$$H^+ = \sum_{i=1}^{n-1} \max(\Delta h_i, 0),$$

natomiast suma zejść obejmuje wartości bezwzględne różnic ujemnych:

$$H^- = \sum_{i=1}^{n-1} \max(-\Delta h_i, 0).$$

Wartości dystansu oraz przewyższeń zależą od jakości i rozdzielczości danych wejściowych. W badaniach nad trasami trailowymi wykazano, że zmiana rozdzielczości przestrzennej pliku GPX wpływa na obliczany dystans oraz skumulowane przewyższenia.[13] Dodatkowo błąd pomiaru GPS może prowadzić do zniekształcenia długości trajektorii, w tym do jej systematycznego zawyżania w określonych warunkach.[16]

Z punktu widzenia kosztu obliczeniowego obliczanie dystansu, sumy podejść i sumy zejść wymaga jednokrotnego przejścia po sekwencji punktów. Każdy punkt, poza pierwszym, jest porównywany z punktem poprzednim, dlatego liczba operacji rośnie liniowo wraz z liczbą punktów trasy.

1.3.2 Porównywanie trasy z trasą referencyjną

Porównywanie śladu zawodnika z trasą referencyjną wymaga przyjęcia geometrycznej reprezentacji trasy wzorcowej. W modelu danych przestrzennych PostGIS geometria typu `LineString` jest opisywana jako linia tworzona przez ciąg segmentów, przy czym każdy segment jest wyznaczony przez dwa punkty, a koniec jednego segmentu jest początkiem następnego.[17] Taki model odpowiada reprezentacji trasy jako uporządkowanej sekwencji punktów.

Trasa referencyjna może być więc traktowana jako linia łamana utworzona z kolejnych punktów. Sąsiednie punkty tej trasy tworzą segmenty, względem których oceniane jest położenie punktów śladu zawodnika. Lokalne porównanie przebiegu tras można wówczas sprowadzić do obliczenia odległości punktu od segmentu trasy referencyjnej.

Dla odcinka AB oraz punktu C najbliższy punkt na odcinku można wyznaczyć przez rzutowanie punktu C na prostą przechodzącą przez A i B , a następnie sprawdzenie, czy punkt rzutu znajduje się wewnątrz odcinka.[18] Jeżeli rzut znajduje się na odcinku, to on jest punktem najbliższym względem C . Jeżeli rzut wypada poza odcinkiem, najbliższym punktem jest jeden z końców odcinka.[18]

W ujęciu parametrycznym punkt na prostej przechodzącej przez końce odcinka można zapisać jako:

$$P(t) = A + t(B - A).$$

Wartość parametru t określa położenie rzutu względem odcinka. Dla $0 \leq t \leq 1$ punkt $P(t)$ znajduje się na odcinku AB . Dla $t < 0$ najbliższym punktem odcinka jest A , natomiast dla $t > 1$ najbliższym punktem jest B . [18]

W zależności od wartości parametru t otrzymuje się trzy przypadki:

- dla $t < 0$ najbliższym punktem jest początek segmentu,
- dla $0 \leq t \leq 1$ najbliższym punktem jest rzut punktu na segment,
- dla $t > 1$ najbliższym punktem jest koniec segmentu.

Odległość punktu śladu od segmentu może zostać obliczona jako odległość euklidesowa między punktem C a wyznaczonym punktem najbliższym $P(t)$. Jeżeli punkt śladu jest porównywany z wieloma segmentami trasy referencyjnej, minimalna z otrzymanych odległości może być traktowana jako lokalne odchylenie śladu od przebiegu trasy wzorcowej.

Przy prostym podejściu obliczeniowym każdy punkt śladu zawodnika jest porównywany z segmentami trasy referencyjnej. Koszt takiej operacji zależy więc od liczby punktów śladu oraz liczby segmentów trasy referencyjnej. Dla m punktów śladu zawodnika i s segmentów trasy referencyjnej liczba sprawdzanych relacji punkt–segment rośnie proporcjonalnie do $m \cdot s$.

1.3.3 Dyskretna odległość Fréchet

Dyskretna odległość Fréchet jest miarą podobieństwa krzywych łamanych reprezentowanych przez skończone sekwencje punktów. W odróżnieniu od porównania pojedynczych punktów lub lokalnych odległości od segmentów uwzględnia ona uporządkowanie punktów na obu porównywanych krzywych.[19] Cecha ta jest istotna przy analizie śladów GPX, ponieważ trasa ma postać uporządkowanej sekwencji położzeń, a nie nieuporządkowanego zbioru punktów.

Eiter i Mannila definiują dyskretną odległość Fréchet dla dwóch krzywych łamanych P oraz Q , reprezentowanych przez sekwencje punktów:

$$\sigma(P) = (u_1, \dots, u_p),$$

$$\sigma(Q) = (v_1, \dots, v_q).$$

Podstawą definicji jest uporządkowane parowanie punktów obu sekwencji, określane jako *coupling*. [19] Parowanie rozpoczyna się od pierwszych punktów obu sekwencji i kończy na ich ostatnich punktach. W kolejnych krokach można przejść do następnego punktu pierwszej krzywej, do następnego punktu drugiej krzywej albo do następnych punktów obu krzywych jednocześnie. Dzięki temu zachowana zostaje kolejność punktów, a jednocześnie możliwe jest porównywanie sekwencji o różnej liczbie próbek.

Długość danego parowania jest określana jako największa odległość pomiędzy punktami występującymi w sparowanych parach. Dyskretna odległość Fréchet odpowiada

najmniejszej możliwej wartości tej największej odległości, rozpatrywanej po wszystkich dopuszczalnych uporządkowanych parowaniach punktów obu krzywych.[19] Wynik tej miary nie zależy więc od pojedynczego lokalnego dopasowania, lecz od najlepszego możliwego przejścia po obu sekwencjach z zachowaniem ich kolejności.

Obliczenie dyskretnej odległości Fréchet’a można przeprowadzić metodą programowania dynamicznego. Dla każdej pary punktów u_i oraz v_j wyznaczana jest wartość opisująca najlepsze dopasowanie początkowych fragmentów obu sekwencji kończących się odpowiednio w tych punktach. Wartość ta zależy od wcześniej obliczonych sąsiednich stanów oraz od odległości $d(u_i, v_j)$ między aktualnie porównywanymi punktami.[19]

Dla przypadku $i > 1$ oraz $j > 1$ zależność rekurencyjną można zapisać następująco:

$$c(i, j) = \max(\min\{c(i-1, j), c(i-1, j-1), c(i, j-1)\}, d(u_i, v_j)).$$

Wartość $c(i, j)$ oznacza najmniejszą możliwą wartość maksymalnej odległości potrzebnej do dopasowania początkowych fragmentów obu sekwencji kończących się w punktach u_i oraz v_j . Dla sekwencji o długościach p oraz q algorytm wymaga rozpatrzenia par punktów obu krzywych, dlatego jego złożoność czasowa wynosi $O(pq)$.[19]

W analizie śladów GPX dyskretna odległość Fréchet’a może służyć do porównania trasy zawodnika z trasą referencyjną na poziomie całego przebiegu trasy. W przeciwieństwie do lokalnego sprawdzania odległości pojedynczych punktów od segmentów trasy referencyjnej metoda ta uwzględnia uporządkowanie punktów w obu sekwencjach. Jej koszt obliczeniowy jest jednak większy niż w przypadku operacji liniowych, ponieważ wymaga analizy relacji pomiędzy punktami obu porównywanych śladów.

Rozdział 2

Reprezentacja danych i narzędzia obliczeniowe w Pythonie

2.1 Python i reprezentacja danych liczbowych

2.1.1 Listy Pythona i dynamiczne typowanie

2.1.2 NumPy i tablice numeryczne

2.1.3 Numba i kompilacja JIT

Rozdział 3

Projekt i implementacja oprogramowania do analizy tras GPX

3.1 Struktura projektu

3.2 Implementacja parsera plików GPX

3.3 Implementacja operacji analizy tras

3.3.1 Obliczanie dystansu i przewyższeń

3.3.2 Porównywanie trasy zawodnika z trasą referencyjną

3.3.3 Obliczanie dyskretnej odległości Fréchet

3.4 Implementacja benchmarków

Bibliografia

- [1] T. Kapeła, *Architektura systemów informatycznych. Architektura i organizacja pamięci*, materiał dydaktyczny (PDF), tryb dostępu: <https://ww2.ii.uj.edu.pl/~kapela/pn/ASI5.pdf>, (dostęp: 2 marca 2026 r.).
- [2] J. Kazimirski, *Architektura komputerów*, materiał dydaktyczny (PDF), tryb dostępu: <https://jankazimirski.pl/files/5AKW.07.pdf>, (dostęp: 2 marca 2026 r.).
- [3] Topografix, *GPX 1.1 Schema Documentation*, informacje o strukturze GPX i odniesieniu do WGS84, tryb dostępu: <https://www.topografix.com/gpx/1/1/>, (dostęp: 2 marca 2026 r.).
- [4] P. J. Denning, *The Working Set Model for Program Behavior*, „Communications of the ACM”, 1968, t. 11, nr 5, s. 323–333, tryb dostępu: https://denninginstitute.com/pjd/PUBS/WSModel_1968.pdf, (dostęp: 2 marca 2026 r.).
- [5] Python Software Foundation, *Memory Management* (Python/C API Reference Manual), tryb dostępu: <https://docs.python.org/3/c-api/memory.html>, (dostęp: 3 marca 2026 r.).
- [6] Python Software Foundation, *The Python Language Reference: Data model*, tryb dostępu: <https://docs.python.org/3/reference/datamodel.html>, (dostęp: 3 marca 2026 r.).
- [7] Platforma PLGrid, *Model Roofline*, tryb dostępu: <https://kompendium.plgrid.pl/podstawy/pojecia/roofline/>, (dostęp: 2 marca 2026 r.).
- [8] L. Szustak, *Architektura i elementy składowe systemów komputerowych* (wykład; slajdy), Politechnika Częstochowska, fragment dotyczący taksonomii Flynna, tryb dostępu: https://icis.pcz.pl/~lszustak/students/ASK/wyklady/ASK_L03.pdf, (dostęp: 2 marca 2026 r.).
- [9] R. Walkowiak, *Analiza efektywności przetwarzania współbieżnego* (materiały dydaktyczne), Politechnika Poznańska, fragment dotyczący prawa Amdahla, tryb dostępu: https://www.cs.put.poznan.pl/rwalkowiak/pliki/2016/pr/pr_efektywnosc_2014.pdf, (dostęp: 2 marca 2026 r.).

- [10] OpenMP Architecture Review Board, *OpenMP API Specification 5.1 – simd construct*, tryb dostępu: <https://www.openmp.org/spec-html/5.1/openmpsu49.html>, (dostęp: 2 marca 2026 r.).
- [11] J. Januszewski, *Systemy satelitarne GPS, Galileo i inne*, Wydawnictwo Naukowe PWN, Warszawa, 2010.
- [12] *Obowiązujące układy współrzędnych a lokalizacja przestrzenna* (materiał informacyjny), Uniwersytet Morski w Gdyni, fragment dotyczący WGS84, tryb dostępu: <https://www.umgd.gov.pl/wp-content/uploads/2017/01/zg-mgm-uklady-wspolrzednych.pdf>, (dostęp: 2 marca 2026 r.).
- [13] R. Sanchez, P. E. Egli, K. Jornet, M. Duggan, M. Besomi, *How fractal complexity distorts distance and elevation gain in trail and mountain running: The case for course measurement standardization*, „Proceedings of the Institution of Mechanical Engineers, Part P: Journal of Sports Engineering and Technology”, 2025, doi: <https://doi.org/10.1177/17543371251341660>.
- [14] University of Cambridge, *The great circle distance*, Underground Mathematics, tryb dostępu: <https://undergroundmathematics.org/trigonometry-compound-angles/the-great-circle-distance>, (dostęp: 16 maja 2026 r.).
- [15] R. Sanchez, C. Nieto-Jimenez, C. Riveros-Matthey, *High-Precision Mapping of Mountain Terrain for Human Locomotion Research: A Multimodal Geospatial Framework*, 2025 15th IEEE International Conference on Pattern Recognition Systems (ICPRS), 2025, doi: <https://doi.org/10.1109/ICPRS66293.2025.11302827>.
- [16] P. Ranacher, R. Brunauer, W. Trutschnig, S. Van der Spek, S. Reich, *Why GPS makes distances bigger than they are*, „International Journal of Geographical Information Science”, 2016, t. 30, nr 2, s. 316–333, doi: <https://doi.org/10.1080/13658816.2015.1086924>.
- [17] PostGIS Project, *Chapter 4. Data Management*, dokumentacja PostGIS, sekcja *Spatial Data Model*, tryb dostępu: https://postgis.net/docs/using_postgis_dbmanagement.html, (dostęp: 16 maja 2026 r.).
- [18] C. Ericson, *Real-Time Collision Detection*, Morgan Kaufmann, San Francisco, 2005, rozdz. 5.1.2: *Closest Point on Line Segment to Point*, ISBN 978-1-55860-732-3.
- [19] T. Eiter, H. Mannila, *Computing Discrete Fréchet Distance*, Technical Report CD-TR 94/64, Christian Doppler Laboratory for Expert Systems, Technische Universität Wien, 1994, tryb dostępu: <https://www.kr.tuwien.ac.at/staff/eiter/et-archive/files/cdtr9464.pdf>, (dostęp: 17 maja 2026 r.).

Spis listingów

1.1	Fragment przykładowego pliku GPX	14
-----	--	----

